

# Documentation du projet RecruitAI

Groupe GBL-ALM

2025 – 2026

## 1 Structure du dossier CODE\_GBL-ALM

CODE\_GBL-ALM/

```
20CVs/..... CVs au format texte pour les tests
  cv_01.txt..... CV1 (Sophie Marchand)
  cv_02.txt..... CV2 (Rayan Kowalski)
  .....
  cv_20.txt..... CV20 (Isabelle Dumont)

RecruitAI_Code/..... Code de l'application web
  app.py..... Serveur Flask (backend)
  requirements.txt..... Liste des dépendances
  static/
    style.css..... Styles CSS
  templates/
    index.html..... Interface utilisateur
  uploads/..... Dossier temporaire (auto-cr  )

Strategy_choice.ipynb..... Notebook d'exp  rimentation
Strategy_choice.pdf..... Version PDF du notebook

cv_to_texte.ipynb..... Notebook extraction PDF
cv_to_texte.pdf..... Version PDF du notebook d'extraction
```

## 2 Dossier 20CVs/

Ce dossier contient les 20 CVs factices au format texte utilis  s pour tester et valider les strat  gies de chunking dans le notebook `Strategy_choice.ipynb`. Chaque fichier `cv_XX.txt` correspond    un profil diff  rent :

- **Profils tr  s pertinents** : CV1, CV2, CV3, CV10, CV15
- **Profils pertinents** : CV4, CV9, CV14
- **Profils moyennement pertinents** : CV5, CV6, CV12
- **Profils peu ou non pertinents** : CV7, CV8, CV11, CV13, CV16, CV17, CV18, CV19, CV20

## 3 Application web - RecruitAI\_Code

### 3.1 Description des fichiers

| Fichier/Dossier      | Description                                                                     |
|----------------------|---------------------------------------------------------------------------------|
| app.py               | Serveur Flask : extraction PDF, chunking, embeddings, classement des CVs        |
| requirements.txt     | Bibliothèques Python à installer (Flask, numpy, sentence-transformers, PyMuPDF) |
| static/style.css     | Feuille de style pour l'interface (design moderne)                              |
| templates/index.html | Page web principale (formulaire, résultats)                                     |
| uploads/             | Stockage temporaire des CVs (vidé automatiquement)                              |

TABLE 1 – Fichiers de l'application web

### 3.2 Installation et exécution

#### 3.2.1 Étape 1 : Se placer dans le dossier

```
cd CODE_GBL-ALM/RecruitAI_Code
```

#### 3.2.2 Étape 2 : Créer un environnement virtuel (optionnel)

Windows :

```
python -m venv venv  
venv\Scripts\activate
```

Linux/Mac :

```
python -m venv venv  
source venv/bin/activate
```

#### 3.2.3 Étape 3 : Installer les dépendances

```
pip install -r requirements.txt
```

#### 3.2.4 Étape 4 : Lancer l'application

```
python app.py
```

#### 3.2.5 Étape 5 : Accéder à l'interface

Ouvrir un navigateur et aller à : <http://localhost:5000>

### 3.3 Fonctionnalités

- Import de l'offre d'emploi (texte ou fichier PDF/TXT)
- Upload de CVs (format PDF) par glisser-déposer
- Choix de la stratégie de chunking (adaptative, sauts de ligne, mots fixes, phrases)
- Classement automatique des candidats par similarité cosinus
- Fiche détaillée du candidat : score, infos personnelles, compétences détectées, bloc décisif
- Visualisation et téléchargement du CV complet au format TXT

## 4 Notebook d'expérimentation - Strategy\_choice.ipynb

### 4.1 Objectif

Ce notebook contient le travail d'expérimentation et de validation des stratégies de chunking. Il a permis de déterminer quelle stratégie est la plus performante.

### 4.2 Contenu

- Chargement du modèle : paraphrase-multilingual-MiniLM-L12-v2
- Prétraitement des CVs
- Implémentation de 6 stratégies de chunking :
  1. chunk\_by\_newlines : découpage par sauts de ligne
  2. chunk\_by\_words : découpage par mots fixes avec chevauchement
  3. chunk\_by\_sentences : découpage par phrases
  4. chunk\_semantic : découpage sémantique
  5. chunk\_fusion : fusion pondérée des stratégies
  6. chunk\_adaptatif : découpage hiérarchique adaptatif
- Jeu de données : 20 CVs factices (dossier 20CVs/)
- Métriques : NDCG, Spearman, Precision@3, Precision@5, MRR

### 4.3 Résultats

| Stratégie          | NDCG   | Spearman | P@3  | P@5  | MRR  |
|--------------------|--------|----------|------|------|------|
| chunk_adaptatif    | 0.9789 | 0.7805   | 1.00 | 0.60 | 1.00 |
| chunk_semantic     | 0.9554 | 0.6030   | 0.67 | 0.60 | 1.00 |
| chunk_by_newlines  | 0.9516 | 0.6827   | 0.67 | 0.60 | 1.00 |
| chunk_by_words     | 0.9361 | 0.6647   | 0.33 | 0.40 | 1.00 |
| chunk_fusion       | 0.9369 | 0.6241   | 0.33 | 0.40 | 1.00 |
| chunk_by_sentences | 0.8808 | 0.2947   | 0.00 | 0.20 | 0.10 |

TABLE 2 – Comparaison des six stratégies de chunking

### 4.4 Version PDF

Une version PDF du notebook (Strategy\_choice.pdf) est également fournie pour une consultation facile sans exécuter le code.

## 5 Notebook d'extraction PDF - cv\_to\_texte.ipynb

### 5.1 Objectif

Ce notebook contient les fonctions d'extraction et de nettoyage de texte à partir de fichiers PDF. Il a servi de base pour développer le module d'extraction utilisé dans l'application web.

## 5.2 Contenu

- Extraction de texte avec PyMuPDF
- Gestion des mises en page complexes (colonnes)
- Détection et reconstruction des colonnes
- Nettoyage du texte (suppression emojis, puces, barres de progression)
- Transformation des barres de progression en texte lisible (ex : "Python niveau 4/5")
- OCR avec Tesseract pour les PDF scannés (optionnel)

## 5.3 Fonctions principales

| Fonction                            | Rôle                                                    |
|-------------------------------------|---------------------------------------------------------|
| <code>extraire_lignes_page()</code> | Extrait les lignes d'une page avec leurs coordonnées    |
| <code>clusteriser_colonnes()</code> | Regroupe les lignes par colonnes                        |
| <code>reconstruire_page()</code>    | Reconstruit le texte d'une page (gestion colonnes)      |
| <code>nettoyer_cv_final()</code>    | Nettoie le texte (emojis, puces, barres de progression) |
| <code>extraire_texte_cv()</code>    | Fonction principale d'extraction                        |

TABLE 3 – Fonctions principales du notebook `cv_to_texte.ipynb`

## 5.4 Version PDF

Une version PDF du notebook (`cv_to_texte.pdf`) est également fournie pour une consultation facile sans exécuter le code.

## 6 Auteurs

- Louiza GACI (2515409)
  - Nada Abir BOUHADJAR (2512053)
  - Mohand GUESSAS (22423442)
  - Aymene LAZREG (22401059)
- Encadré par : Pascal PONCELET  
Université de Montpellier - Master IASD  
Année universitaire : 2025 – 2026